TP1 :

Etape 1 : Charger les données : le dataset Iris

```
print(df.describe())
```

```
=== EXPLORATION DES DONNÉES ===
Forme du dataset : (150, 5)

Distribution des classes :
species
setosa        50
versicolor    50
virginica     50
Name: count, dtype: int64

Valeurs manquantes : 0

Aperçu :
   sepal_length  sepal_width  petal_length  petal_width species
0           5.1          3.5           1.4          0.2  setosa
1           4.9          3.0           1.4          0.2  setosa
2           4.7          3.2           1.3          0.2  setosa

Statistiques descriptives :
       sepal_length  sepal_width  petal_length  petal_width
count    150.000000   150.000000    150.000000   150.000000
mean       5.843333     3.057333      3.758000     1.199333
std        0.828066     0.435866      1.765298     0.762238
min        4.300000     2.000000      1.000000     0.100000
25%        5.100000     2.800000      1.600000     0.300000
50%        5.800000     3.000000      4.350000     1.300000
75%        6.400000     3.300000      5.100000     1.800000
max        7.900000     4.400000      6.900000     2.500000
```

1 - Nombre d'échantillons par classe et équilibre du dataset :

- Il y a 50 échantillons pour chaque classe (setosa, versicolor, virginica).
- Le dataset est équilibré car toutes les classes ont le même nombre d'échantillons.

2 - Valeurs manquantes :

Non, il n'y a pas de valeurs manquantes dans le dataset. La sortie indique clairement "Valeurs manquantes : 0".

3 - Variables les plus discriminantes :

D'après les statistiques descriptives, les variables petal_length (longueur du pétale) et petal_width (largeur du pétale) semblent être les plus discriminantes.

Ces variables ont des écarts types plus élevés par rapport aux autres (sepal_length et sepal_width), ce qui suggère une plus grande variabilité entre les classes.

Pour une analyse plus précise, il serait utile de visualiser ces variables avec des graphiques comme des boxplots ou des distributions par classe.

Avec le graphique, certaines paires de variables permettent effectivement de séparer visuellement les trois espèces (setosa, versicolor, virginica).

Les paires de variables les plus efficaces pour séparer visuellement les trois espèces sont celles qui impliquent petal_length ou petal_width, en particulier avec sepal_length. La paire « petal_length vs petal_width » semble la plus efficace globalement, car elle permet une distinction claire de setosa et montre une certaine séparation entre versicolor et virginica.

Etape 2 : Entraîner un modèle : baseline + modèle principal

```
Entraînement : 120 échantillons | Test : 30 échantillons
Modèles entraînés.
```

Un decision tree est généralement plus rapide à entraîner qu'un Random Forest, ce qui est pratique dans notre cas.
Ca évite de perdre du temps sur un modèle complexe si la baseline donne déjà de bons résultats.
On évite également le sur-apprentissage et pour ce modèle, un decision tree peut déjà atteindre une précision élevée.

Etape 3 : Évaluer les métriques

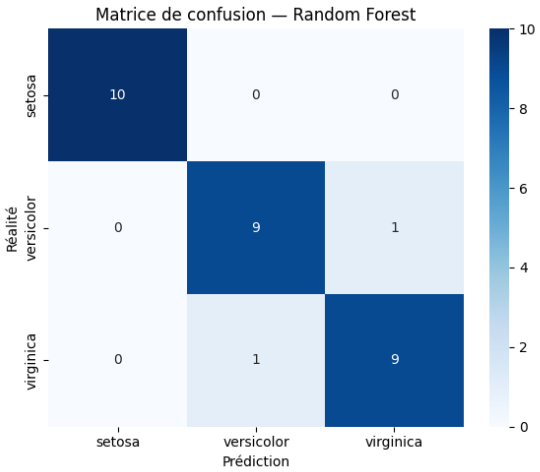

Le Random forest ne surpasse pas le decision tree dans ce cas, car :
- Decision tree (baseline) :
    - Accuracy : 96.7%
    - F1-score (weighted) : 0.967
- Random forest :
    - Accuracy : 93.3%
    - F1-score (weighted) : 0.933

Avec ces statistiques, le decision tree a une meilleure performance que le random forest.

Y a-t-il des espèces plus difficiles à classifier que d’autres ?

Oui, les espèces comme les versicolor et virginica sont plus difficiles à classer que les setosa.
La setosa est classée 10/10 dans le test avec une précision et un rappel de 1.
Versicolor et virginica ont des performances légèrement moins bonnes, avec une précision et un rappel de 0.90.

Quelle différence entre accuracy et F1-score ? Dans quel cas préférer l’un à l’autre ?

Accuracy :
- Mesure la proportion d'échantillons correctement classés par rapport au total
- Simple à interpréter, mais peut être moins précise si le dataset est déséquilibré (par exemple, si une classe domine, une accuracy élevée ne signifie pas que le modèle est bon pour les autres classes)
- Dans notre cas, l'accuracy est élevée (93.3% pour Random Forest) car setosa est parfaitement classée et les erreurs concernent seulement versicolor et virginica

F1-score :
- Moyenne harmonique de la précision et du rappel
- Utile pour les problèmes déséquilibrés ou lorsque l'on veut pondérer à la fois les faux positifs et les faux négatifs
- Le F1-score pondéré (weighted) prend en compte le nombre d'échantillons dans chaque classe, ce qui le rend plus robuste que l'accuracy si les classes sont de tailles différentes. Ici,

comme les classes sont équilibrées (50 échantillons chacune), le F1-score pondéré est similaire à l’accuracy

Quand préférer l'un ou l'autre ?

Préférer l'accuracy si le dataset est équilibré et que l'on s'intéresse uniquement à la proportion globale d’erreurs.

Préférer le F1-score si le dataset est déséquilibré (une classe domine),si on s'intéresse à une classe spécifique, ou si on veut pondérer les erreurs de faux positifs et faux négatifs de manière équilibrée.

Etape 4 : Tuning des hyperparamètres et détection de l’overfitting

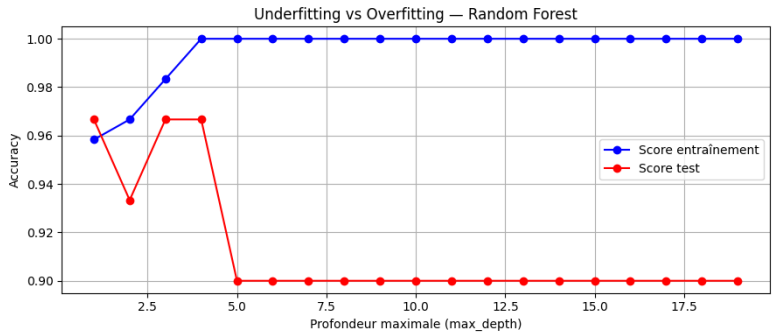

Question 1 : À partir de quelle profondeur observe-t-on de l’overfitting (score train >> score test) ?

L'overfitting apparaît sur le graphique à partir de max_depth = 4, où le score de test chute, tandis que le score d'entraînement reste au max.

Question 2 : Quel nombre d’arbres offre le meilleur compromis performance / coût de calcul ?

Le meilleur compromis est n_estimators=10, car il offre une performance légèrement supérieure (95.8%) avec une stabilité parfaite, tout en étant bien moins coûteux en termes de calcul que les autres valeurs testées.

Question 3 : Qu’apporte la validation croisée par rapport à un simple split train/test ?

La validation croisée apporte :
- Une meilleure estimation des performances grâce à une utilisation optimale des données
- Une réduction de la variance par rapport à un simple split train/test
- Une détection plus fiable de l'overfitting ou de l'underfitting

Dans notre cas, elle montre que le modèle est stable (écart-type ±1.7%) et performant en moyenne (95.0%), ce qui est plus informatif qu'un seul split.

Étape 5 — Explicabilité SHAP

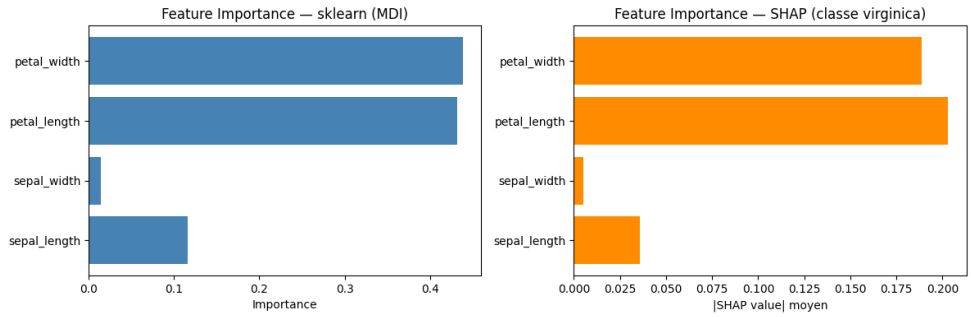

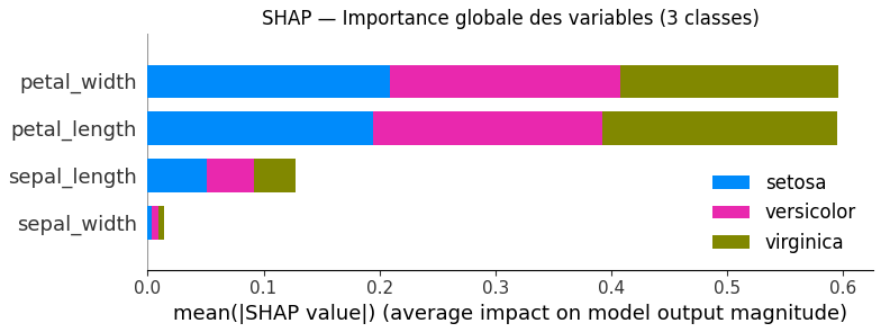

D'après le graphique SHAP et les analyses précédentes, les variables liées aux pétales (petal_length et petal_width) sont effectivement les plus discriminantes pour séparer les espèces, notamment setosa des autres.

La variable petal_width est la plus déterminante selon SHAP, suivie de petal_length. Cela est tout à fait cohérent avec l'intuition et les analyses précédentes, car ces variables permettent une meilleure séparation des classes, notamment pour setosa.

Quelle différence entre l'importance sklearn (MDI) et l'importance SHAP ?

MDI est une mesure globale qui ne tient pas compte de la direction de l'impact (positif ou négatif) ni de la manière dont la variable influence individuellement chaque prédiction, tandis que SHAP donne une idée de la direction de l'impact : par exemple avec notre modèle, une valeur élevée de petal_width peut pousser vers la classe virginica.

Pourquoi l'explicabilité est-elle cruciale dans un contexte réglementé (médical, crédit bancaire) ?

Dans ces domaines, les décisions ont un impact significatif sur les individus, il est donc essentiel d'avoir de la transparence et de la confiance, une conformité réglementaire stricte (RGPD par exemple), de la responsabilité (assumer certains résultats), et utiliser ces explications également pour l'amélioration des modèles.

Etape 6 : Debrief : 3 insights clés

Insight 1 — Observation de performance:
Observation : La performance du modèle (par exemple, précision ou F1-score) atteint un plateau à une certaine profondeur d'arbre.
Explication : Cela signifie que le modèle a atteint ses limites en termes de capacité à généraliser. Au-delà d'une certaine profondeur, l'ajout de nœuds supplémentaires n'améliore pas significativement la performance et peut même la dégrader.
Implication pratique : Il faut arrêter l'entraînement ou limiter la profondeur des arbres pour éviter un sur-ajustement (overfitting) tout en maintenant une bonne performance.

Insight 2 — Overfitting / généralisation observation :
Observation : L'erreur de validation commence à augmenter alors que l'erreur d'entraînement continue de diminuer, ce qui se produit généralement à partir d'une certaine profondeur d'arbre (par exemple, profondeur = 5).
Explication : L'overfitting survient lorsque le modèle apprend trop bien les données d'entraînement et capture du bruit ou des variations spécifiques à l'échantillon d'entraînement, plutôt que la structure sous-jacente des données. Cela se traduit par une mauvaise généralisation sur de nouvelles données.
Implication pratique : Pour éviter l'overfitting, il faut choisir une profondeur d'arbre qui minimise l'erreur de validation ou utiliser des techniques comme le pruning (taille des arbres), la régularisation, ou le dropout pour les réseaux de neurones. Il est aussi utile de valider le modèle sur un ensemble de validation séparé.

Insight 3 — Explicabilité observation :
Observation : Selon SHAP, petal_width est la variable la plus importante, suivie de près par petal_length.
Explication : Cela est cohérent avec les analyses précédentes qui montrent que ces deux variables permettent une bonne séparation des classes. Cependant, cela peut être surprenant si on s'attendait à ce que sepal_length ou sepal_width soient plus discriminantes, car elles ont des variances plus faibles.
Implication pratique : Dans un contexte réglementé comme la médecine ou le crédit bancaire, l'explicabilité est obligatoire pour garantir la transparence et éviter les biais. Il est crucial de comprendre comment chaque variable influence les prédictions, notamment pour des raisons de conformité et de responsabilité.